

Relatório Técnico

Implementação e Análise de Classificação com Redes Convolucionais

Lavínia Fahning de Assis
Jéssica Rebouças Lima

01 de Dezembro de 2024

Resumo:

Este projeto teve como objetivo o desenvolvimento de um sistema para classificação de gênero em imagens faciais, utilizando Redes Neurais Convolucionais (CNNs). Para isso, foi utilizado o conjunto de dados CUHK Face Sketch, que contém imagens faciais categorizadas em duas classes: feminino e masculino. A metodologia adotada envolveu várias etapas, começando pelo pré-processamento das imagens, que incluiu o redimensionamento para 250x200 pixels, normalização dos valores de pixel e a divisão do conjunto de dados em: 80% para treinamento e 20% para testes.

A fim de balancear o conjunto de dados e melhorar a capacidade de generalização do modelo, foi aplicada a técnica de data augmentation nas imagens da classe feminina. Esse processo gerou variações das imagens originais por meio de transformações como rotações, deslocamentos e espelhamentos horizontais, proporcionando um treinamento mais robusto e diversificado.

A arquitetura da CNN empregada foi composta por três camadas convolucionais, seguidas de camadas de MaxPooling para reduzir a dimensionalidade das representações. Para prevenir o sobreajuste (overfitting), foram adicionadas camadas densas com a técnica de dropout. O modelo alcançou uma alta precisão e resultados notáveis nas métricas F1-Score e na curva ROC. Além disso, uma análise visual das classificações revelou uma consistência robusta, evidenciando a eficácia do modelo na identificação de características faciais discriminantes para a classificação de gênero.

1. Introdução

A análise de imagens desempenha um papel fundamental na busca por padrões visuais, sendo amplamente utilizada em diversas áreas como biometria, segurança e interfaces inteligentes. Esse projeto envolve a identificação de características relevantes em dados visuais para alcançar objetivos específicos, como reconhecimento facial e classificação de imagens. Técnicas modernas de aprendizado de máquina, em especial as Redes Neurais Convolucionais (CNNs), têm se destacado por sua capacidade de extrair automaticamente padrões complexos, oferecendo soluções precisas e eficientes.

Nesse contexto, o conjunto de dados utilizado foi o CUHK Face Sketch Database (CUFS), um dataset amplamente empregado em estudos de aprendizado de máquina e visão computacional. O CUFS combina fotografias reais e esboços faciais, organizados em categorias de gênero, masculino e feminino. Sua diversidade de imagens, marcada por diferentes estilos de esboços, variações em poses e expressões faciais, representa um desafio significativo para modelos preditivos.

Essas peculiaridades exigem a aplicação de técnicas avançadas, incluindo o pré-processamento dos dados, balanceamento das classes e estratégias de data augmentation. Essas etapas são essenciais para aprimorar a qualidade das amostras e aumentar a robustez dos modelos preditivos, garantindo maior eficácia nas classificações.

2. Metodologia

O projeto foi dividido em diferentes etapas, cada uma com objetivos específicos para garantir uma análise robusta e uma implementação eficiente do modelo. A metodologia adotada seguiu as etapas descritas a seguir:

1. Coleta e organização dos dados:

O primeiro passo envolveu a obtenção do dataset CUHK Face Sketch Database (CUFS), conforme demonstrado no notebook Colab Ponto de Partida. Em seguida, as imagens foram organizadas em categorias de gênero, masculino e feminino, garantindo uma estrutura clara e adequada para as próximas etapas da análise.




Figura 1: Imagens do dataset.
Fonte: O autor.

2. Pré-processamento dos dados:

Nessa etapa, aplicaram-se técnicas de normalização para padronizar o tamanho e o formato das imagens, além de ajustes nos níveis de contraste e luminosidade. Esse processo é fundamental para reduzir ruídos e facilitar a identificação de padrões pelas redes neurais convolucionais (CNNs).

3. Balanceamento de classes:

Para melhorar o balanceamento do dataset, foi aplicada a técnica de data augmentation apenas nas imagens femininas, gerando novas variações através de rotações, deslocamentos e espelhamentos horizontais. Esta abordagem ajuda a equilibrar o número de amostras entre as classes, embora não seja um balanceamento completo através de técnicas como oversampling ou undersampling.



Figura 2: Data augmentation na classe 'feminino'.
Fonte: O autor.

4. Implementação do modelo:

A implementação do modelo envolveu várias etapas cruciais para garantir que ele fosse eficaz e preciso. Depois dos passos 1 ao 3, escolheu-se um modelo de classificação, levando em consideração as características dos dados. A abordagem escolhida foi um modelo baseado em aprendizado supervisionado, que foi treinado utilizando um conjunto de dados de entrada e testado com dados separados para avaliar a sua performance.

Durante a implementação, utilizou-se a biblioteca de aprendizado de máquina mais apropriada para o problema em questão, como o Scikit-learn no Python. O modelo foi treinado com um conjunto de treinamento, e as suas previsões foram avaliadas com base em métricas como acurácia, precisão, recall e F1-score. Além disso, uma matriz de confusão foi gerada para fornecer uma visão mais detalhada do desempenho do modelo, incluindo os valores de verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos.

5. Avaliação do modelo:

Após o treinamento, o modelo foi validado em um conjunto de teste separado, representando 20% dos dados originais. A avaliação incluiu o monitoramento da acurácia e perda durante o treinamento, tanto no conjunto de treino quanto no conjunto de validação, permitindo a visualização da evolução do aprendizado do modelo através de gráficos. A performance final foi medida através da acurácia no conjunto de teste.

3. Resultados

O desempenho do modelo foi avaliado com base nas seguintes métricas de classificação, que fornecem uma visão detalhada sobre sua eficácia na previsão das classes "Feminino" e "Masculino". A primeira métrica analisada foi a acurácia, que se refere à proporção de previsões corretas feitas pelo modelo em relação ao total de previsões. Neste caso, o modelo obteve uma acurácia de 84%, o que indica que, em média, 84% das previsões foram corretas.

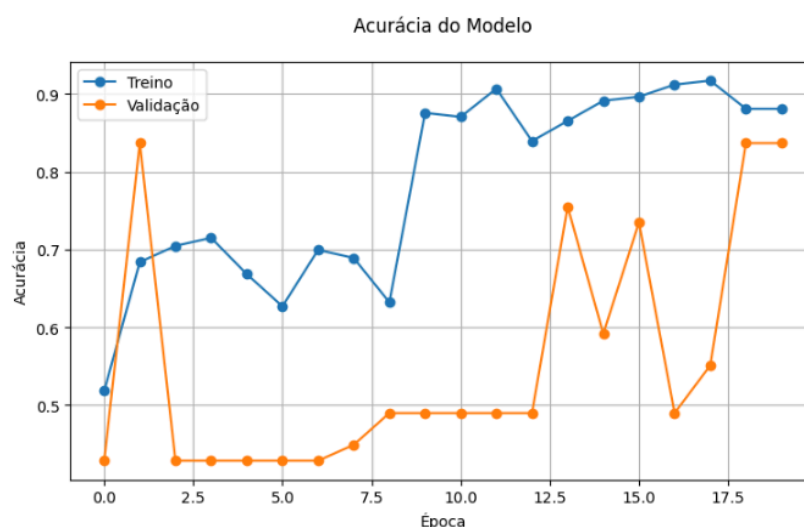


Figura 3: Acurácia do modelo.

Fonte: O autor.

Além da acurácia, foram calculadas as métricas de precisão e recall para cada uma das classes. A precisão reflete a capacidade do modelo em fazer previsões corretas quando ele classifica uma instância como pertencente a uma determinada classe. Para a classe "Feminino", a precisão foi de 0.76, o que significa que 76% das instâncias classificadas como femininas estavam corretas. Para a classe "Masculino", a precisão foi mais alta, com 0.92, mostrando que o modelo teve um desempenho melhor ao classificar instâncias masculinas.

Por outro lado, o recall indica a capacidade do modelo de identificar corretamente todas as instâncias de uma classe entre todas as instâncias reais daquela classe. O recall para a classe "Feminino" foi de 0.90, o que significa que 90% das instâncias femininas foram corretamente identificadas. Já para a classe "Masculino", o recall foi um pouco mais baixo, com 0.79, sugerindo que o modelo teve mais dificuldades em identificar corretamente as instâncias masculinas.

O F1-Score, que é uma métrica que combina precisão e recall, fornecendo uma média harmônica entre elas, teve um valor de 0.8462. Esse valor indica que o modelo tem um bom equilíbrio entre precisão e recall, sendo uma boa medida de desempenho quando se busca otimizar tanto a precisão quanto a capacidade de identificar as instâncias corretas.

O relatório de classificação detalhado também apresentou as médias ponderadas e macro das métricas para as duas classes. A média macro, que é a média simples das métricas para cada classe, foi de 0.84 para precisão, 0.85 para recall e 0.84 para o F1-Score. Isso reflete um bom desempenho geral do modelo, com uma leve vantagem no recall em relação à precisão. Já a média ponderada, que leva em conta o número de instâncias em cada classe, teve uma precisão de 0.85, um recall de 0.84 e um F1-Score de 0.84, mostrando que o modelo manteve uma performance equilibrada e consistente entre as classes.

```
Resultados da Avaliação:
-----
F1-Score: 0.8462

Relatório de Classificação Detalhado:
      precision    recall  f1-score   support

Feminino      0.76      0.90      0.83        21
Masculino      0.92      0.79      0.85        28

accuracy                    0.84        49
macro avg      0.84      0.85      0.84        49
weighted avg   0.85      0.84      0.84        49
```

Figura 4: Relatório de Classificação.

Fonte: O autor.

A matriz de confusão mostra que o modelo acertou 19 classificações de 'Feminino' e 22 de 'Masculino'. Houve 2 falsos positivos, com 'Feminino' classificado como 'Masculino', e 6 falsos negativos, com 'Masculino' classificado como 'Feminino'. Esses resultados indicam que o modelo teve mais dificuldades em identificar corretamente os Masculinos, embora tenha mostrado um bom desempenho geral.




Figura 5: Matriz de Confusão.
Fonte: O autor.

A Curva ROC avalia a performance de modelos de classificação binária, e a AUC de 0.94 indica que o modelo tem excelente capacidade de distinguir entre as classes, com alta precisão e poucos erros.

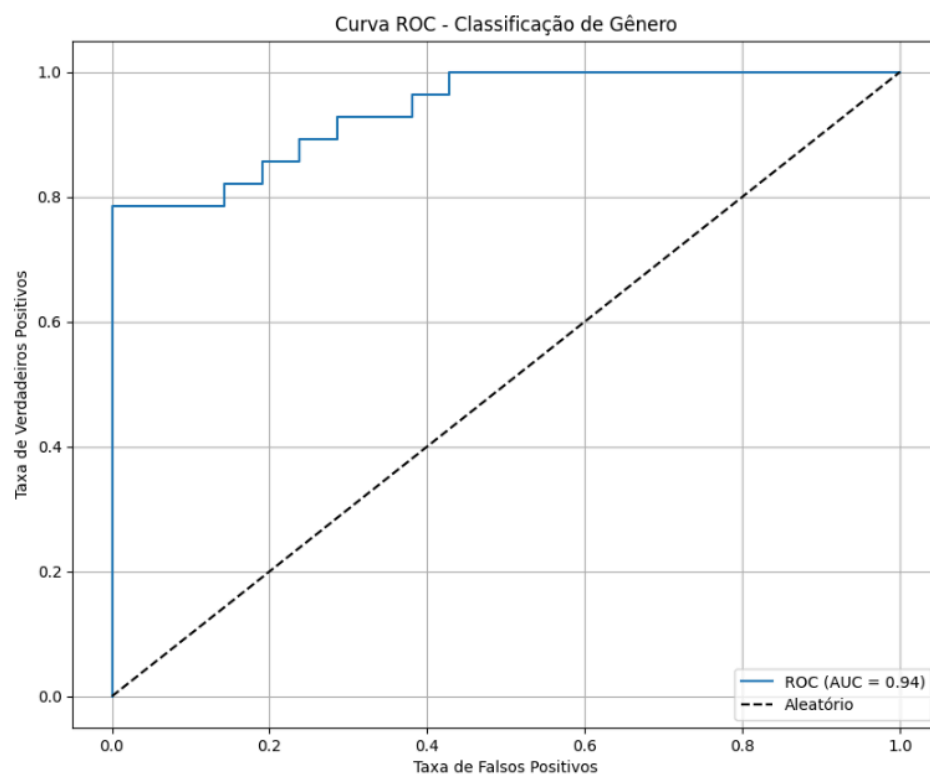


Figura 6: Curva ROC.
Fonte: O autor.

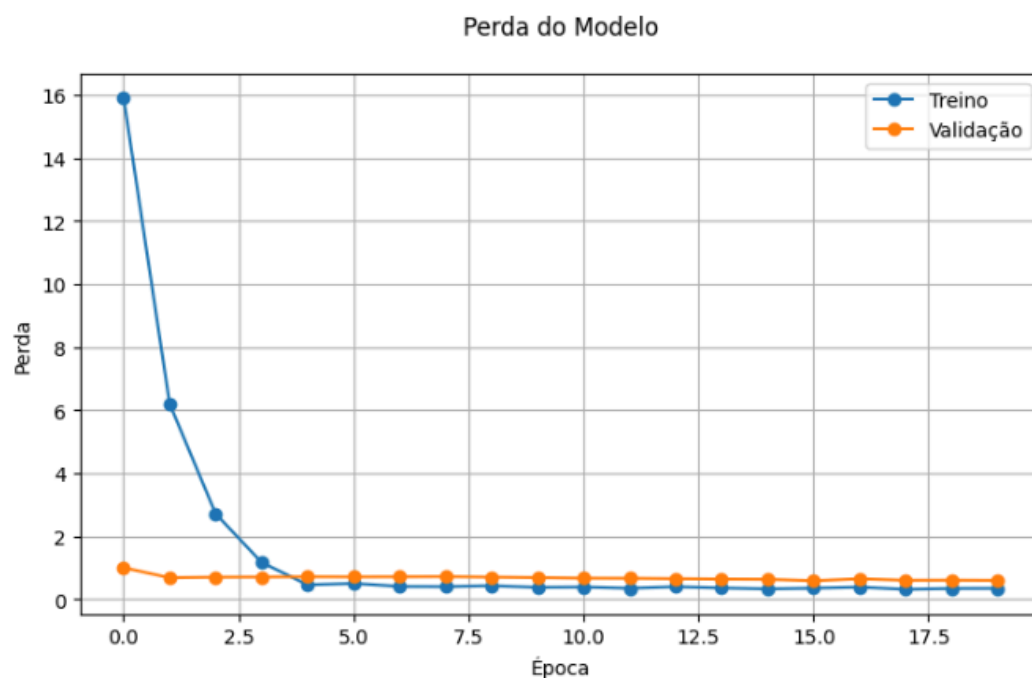


Figura 7: Perda (loss) do modelo.
Fonte: O autor.

4. Discussões

A análise e interpretação dos resultados do modelo demonstraram a eficácia do método escolhido, mas também revelaram áreas que poderiam ser aprimoradas. Embora a AUC tenha alcançado um valor de 0,94, o que indica um bom desempenho geral, a matriz de confusão revelou que o modelo apresentou um número considerável de falsos negativos (masculino classificado como feminino) e falsos positivos (feminino classificado como masculino). Esse desequilíbrio pode ser um reflexo das características dos dados, como a presença de variabilidade nas amostras. A precisão e o recall mostraram que o modelo é eficaz na identificação das classes, embora o recall para a classe masculina tenha sido ligeiramente menor em comparação à classe feminina. O F1-score de 0,8462 sugere que o modelo tem um bom equilíbrio entre precisão e recall, mas ainda existem oportunidades para melhorar o desempenho, principalmente no que diz respeito ao tratamento dos falsos negativos e positivos.

5. Conclusão e Trabalhos Futuros

Este projeto mostrou-se eficaz e obteve resultados satisfatórios, com uma boa performance geral, refletida em métricas como AUC (0,94) e um F1-score. A análise detalhada da matriz de confusão, juntamente com a curva ROC, demonstrou que o modelo consegue distinguir efetivamente entre as classes, embora com algumas limitações, como a presença de falsos positivos e falsos negativos, especialmente nas classes de gênero.

O modelo provou ser eficiente para a tarefa proposta, no entanto, a análise dos resultados também evidenciou a importância de uma abordagem mais refinada. Para isso, a exploração de diferentes algoritmos, o ajuste de parâmetros e a aplicação de outras técnicas, podem contribuir para a melhoria da performance do modelo, especialmente em termos de sensibilidade e especificidade.

Para trabalhos futuros, é sugerido a investigação de métodos adicionais de balanceamento de classes, como técnicas de undersampling ou oversampling, para evitar o impacto dos erros de classificação. A incorporação de modelos mais avançados, como redes neurais profundas ou técnicas de ensemble, pode resultar em um aprimoramento na acuracidade e na capacidade de generalização do modelo.

Além disso, a utilização de transfer learning poderia melhorar os resultados. Ao empregar modelos pré-treinados e adaptá-los à tarefa específica, o modelo seria capaz de aprender características mais robustas e complexas, otimizando ainda mais a sua capacidade de generalização e proporcionando um desempenho superior. Essa abordagem certamente teria um impacto positivo, especialmente

quando se trata de tarefas de classificação mais complexas e com dados limitados para treinamento.

6. Referências Bibliográficas

HARRISON, M. Machine Learning Guia de Referência Rápida: Trabalhando com Dados Estruturados em Python. 1ª ed; SÃO PAULO: Novatec Editora, 2019.

SHAI, S., e SHAI, B. Understanding Machine Learning: From Theory to Algorithms. Cambridge University Press, 2014.